

Pestaña 1

Pregunta: ¿En los cluster, al pasar todas las solicitudes por un nodo cabeza, no se genera cuello de botella?

Pregunta: Hay modelos arquitectónicos de clusters que usan uma y numa al mismo tiempo?

Reflexión: Desde mi punto de vista, las empresas están pasando de ias a soluciones serverless o pas, aumentando las capas de abstracción y poner mas foco a las reglas de negocio, de la misma manera está sucediendo con los lenguajes de programación, y el uso de la IA

Reflexión: En la actualidad, los desarrolladores priorizan rapidez de desarrollo, como ocurre con las prácticas actuales del llamado vibe coding, lo que puede producir software funcional, pero poco eficiente, que es justamente lo que trata la teoría, porque esto puede aumentar el consumo de recursos y energía ya que los mismos no son óptimos o no están basados en la arquitectura. Básicamente está contradiciendo en cierto punto los principios de green computing donde se busca utilizar los sistemas de manera energéticamente responsable.

Pregunta: Por que en un multicomputador se busca que los nodos sean homogéneos?

Pregunta: ¿Cuál podría ser una posible solución al problema de “falsa compartición” entre hilos?

Pregunta: Es mejor invertir en una única máquina multiprocesadora muy potente o en un cluster de muchas máquinas más simples? que factores hay que considerar?

Pregunta: ¿por qué en una arquitectura NUMA se permite que el tiempo de acceso a memoria sea diferente entre procesadores? cuál sería el propósito? podría hacer que algunos procesos sean más lentos que otros? qué ventajas tendría?

Pregunta: En el video se muestra a la supercomputadora "Frontier" como la nro 1 en el ranking dado por Top500, pero al día de la fecha (Nov 2025 la ultima entrega) la supercomputadora "El Capitan" tiene el 1er puesto, con una mejoría de casi 500 exaflops, cual fue el avance tecnológico que permitió que se mejore aún más la velocidad?

Pregunta: por qué motivo se dice que fallo el grid computing y que aplicaciones se le pueden dar hoy en día o que ejemplos del mismo tenemos en la actualidad.

Reflexión: La evolución tecnológica está directamente relacionada con el ambiente que lo rodea. Si se procura su protección, entonces es prometedora y longeva. Si se descuida, tanto el mundo como la tecnología tendrán fecha de expiración.

Pregunta: El cloud computing absorbió funcionalidades del grid computing?

Reflexión/análisis: es posible realizar un análisis de una situación que afecta hoy al consumidor: el precio/disponibilidad de componentes para PC. Se puede observar que, a causa de la inteligencia artificial que utilizan dichas supercomputadoras, los precios de ciertos componentes como las memorias RAM se vieron disparados. Si bien no es una relación directa, es una situación de la actualidad.

Pregunta: En que se basa exactamente el listado de Green500 solo en el consumo de energía? Se tiene en cuenta el resto de factores ambientales a los que este consumo de energía afecta?

Pregunta: Respecto a la clasificación de multiprocesadores, por qué se sigue haciendo distinción entre con y sin coherencia de caché si hoy por hoy todos lo tienen?

Relación:

Respecto a los FLOPS creo que estos aumentan cuando utilizan la arquitectura vista en la materia de Arquitecturas y Organización de Computadoras VLIW/EPIC, donde cada instrucción supera el tamaño de una word convencional, destacándose en una alta performance en cuanto operaciones de números de punto flotante como ocurrió con la Intel Itanium.

[fuente](#) (página 51/hoja 4)

- Ferraris Facundo

Pregunta: ¿Los supercomputadores pueden ser reemplazados por cloud computing a futuro?

Pregunta: ¿Por qué se perdió el interés en el Grid Computing?

Relación: Los transistores me hicieron acordar a los circuitos combinacionales en Arquitectura y Organización de Computadoras, o al menos es muy parecido a las compuertas NAND, AND, NOR, OR y NOT que vimos. Ambos devuelven un valor booleano (o al menos las compuertas devolvieron 1 y 0 según correspondía) a lo que entra por las compuertas

Pregunta: Cuando hablamos de la blockchain, y de que los mineros “minan” un bloque para que se habilite una transacción. ¿Que tipo de computación estamos viendo? Paralela, distribuida, de altas prestaciones, o ciertos conceptos de las 3 juntos?

Reflexión/comentario: : Parece que se vienen problemas energéticos muy grandes con el tema de la inteligencia artificial y los datacenter necesarios para el funcionamiento de las mismas. Dicen que puede llegar a ser que no escale mucho más porque la limitación no es de computación sino energética.

Pregunta: Con nuevos desafíos ambientales por el avance tecnológico, ¿existen regulaciones legales sobre el consumo energético de los sistemas HPC?

Pregunta: ¿El Grid Computing sigue siendo utilizado, pese a la pérdida de interés?

Pregunta: ¿el Cloud Computing se mantuvo igual de vigente hasta ahora? Según el gráfico de búsquedas su mayor impacto fue en 2011

Pregunta: ¿Cuando habla de nodos y componentes en el caso de grid computing, a que se refiere cuando habla que estos son heterogéneos? Así mismo en la definición de nodos da la característica que son homogéneos

Pregunta: ¿El impacto ecológico de la supercomputación es un factor determinante de los aumentos de precios de ciertos componentes en la actualidad?

Pregunta: ¿Qué relación existe entre los IPC dentro de un SO y cómo se comunican los múltiples procesadores en la arquitectura MIMD?

Reflexión: La abstracción del SO para manejar IPC (mediante memoria compartida (smh_open y mmap) permiten que el código se escriba y funcione igual en un procesador antiguo de un solo núcleo (SISD) que en uno moderno de múltiples núcleos (MIMD). La diferencia existe al momento de usar la arquitectura SIMD.

Las supercomputadoras resuelven problemas muy difíciles mediante cálculos para los cuales con las PCs tradicionales se tardaría muchísimo. Si se utilizaran supercomputadoras para manejar grandes volúmenes de datos, se puede considerar que se estaría desaprovechando su uso?

1. Multiprocesadores(Tisiano Arias, Marisol Pereira, Tomás Santiago González). MuLP <https://meet.google.com/csv-sqar-bsk>

Espacio de direcciones global.

2. Multicomputadores (Jeremias Garcia, Eduardo Fernandez, Agostina Addesso)
3. Supercomputadoras (Franco Fabris, Tania Barbieri)
4. Grid Computing (Victoria Bugli, Sthefany Cedeño, Luana Braicovich)
5. Cloud Computing (Alejandro Abele, Rodrigo Chavez)
6. Benchmarks (Guillermo Nicolas Diaz, Franco Fabian Benitez, Luciano Sepulveda)
7. Métricas de rendimiento: Eficiencia computacional y energética (Facundo Muñoz)
8. Evolución de la eficiencia computacional (Agustin Ferreyra, Jeremias Jaleniecki)
9. Evolución del tamaño (Adriano Guido, Luca Tocce, Jose Quintanilla)
10. Evolución de la eficiencia energética (Facundo Ferraris, Andrea Arielle Flores, Torres Andres)
11. Computación ecológica y el impacto económico, social y medioambiental de la supercomputación.(Ignacio Navarro, Giulianna Vicentino, Nicolas Moreno, Tomas Occhi)

Multiprocesador: Máquina con más de una unidad de procesamiento.

Es una máquina de memoria compartida que permite que una computadora trabaje más rápido, ejecute varias tareas a la vez y resuelva problemas complejos de manera más eficiente.

Existen dos tipos de multiprocesadores:

- Microprocesador multicore: Un procesador con muchos núcleos.
- Microprocesadores múltiples: Varios microprocesadores conectados por un sistema de interconexión (buses).

La **coherencia de caché** evita que la CPU lea valores desactualizados de las ubicaciones en memoria. Cada CPU posee su propia memoria caché, pero comparten la memoria RAM, provocando en muchos casos que tengan copias de las mismas posiciones en memoria dentro de sus cachés.

Una **invalidación** surge cuando un Thread modifica una línea de caché y esta misma se encuentra en otra caché de otro procesador, para evitar inconsistencias se invalida la línea. Al invalidar la línea se genera otro problema denominado falsa compartición. La **falsa compartición** es un problema de rendimiento producido por las invalidaciones que hacen que los protocolos de coherencia de caché se realicen sobre la línea completa en caché en vez de la unidad mínima direccionable que es el byte. Este problema puede ocasionar problemas dentro del rendimiento. Para solucionarlo se suele separar a una distancia de una palabra los datos que cada uno posee.

Clasificación

Las máquinas de memoria compartida se clasifican en **UMA Y NUMA** según el tiempo de acceso (latencia) a la RAM.

UMA: Uniform Acces Memory. El tiempo de acceso a cualquier ubicación de la memoria es el mismo para todos los procesadores.

NUMA: Non Uniform Acces Memory: El tiempo de acceso a la memoria no es el mismo para todos los procesadores.

Supercomputación

- Sistemas de Computadoras de Alto Rendimiento (HPC) de gran escala.
- Arquitectura de tipo cluster o MPP
- Utilizan clusters de computadoras potentes para resolver problemas que poseen un conjunto de datos tan masivos que una computadora convencional no puede manejar.
- Generalmente son de propiedad estatal por el costo de producirlas.
- Hay un ranking que las compara por rendimiento, el TOP500
- Hoy en día lo lidera una supercomputadora desarrollada por Hewlett Packard (HP) conocida como El Capitán.

Configuración de un nodo de una supercomputadora cluster/MPP

- Generalmente máquinas de memoria compartida de tipo NUMA con dos sockets
- Presentan aceleradoras, que son procesadores eficientes destinadas a cómputos específicos

Para darse una idea de la escala, a continuación la especificación de la Frontier, la top 1 del TOP500 antes de El Capitán :

- La Frontier tiene un total de 64 servidores Blade, cada uno con 2 nodos
- Cada nodo tiene un CPU, 4 GPUs y 4 terabytes de memoria flash
 - CPU: 512GB de RAM - 64 Cores - 2GHz
 - GPU: 128GB de RAM - 220 Cores -
- Consume 21 megawatts

Cloud Computing

A nivel **físico**, el Cloud Computing se sustenta en una red masiva de **centros de datos** (datacenters) equipados con hardware de alto rendimiento, interconectados para ejecutar aplicaciones y procesar algoritmos a gran escala.

La Capa de Abstracción y Virtualización

La clave de la nube es su **capa de abstracción**. El cliente no interactúa directamente con el hardware físico, sino con una **capa de virtualización**. Esto permite:

- **Segmentación:** Dividir un recurso físico entre múltiples clientes de forma segura.
 - **Escalabilidad:** Aumentar o disminuir recursos de forma inmediata según la demanda.
 - **Eficiencia:** Optimizar el uso de los servidores físicos compartiendo su potencia.
-

Modelos de Servicio (IaaS, PaaS, SaaS)

Actualmente, la oferta de servicios en la nube se divide en tres categorías principales según el nivel de control y gestión que tiene el usuario:

1. **IaaS (Infrastructure as a Service):** Provee recursos de infraestructura básica. Aquí el usuario recibe una Máquina Virtual (VM) o un VPS y tiene control total para instalar el sistema operativo, configurar bases de datos y desplegar aplicaciones desde cero.
 2. **PaaS (Platform as a Service):** Ofrece un entorno listo para el desarrollo. El proveedor gestiona la infraestructura y los entornos de ejecución, permitiendo que el usuario se enfoque exclusivamente en la **lógica de negocio** y el código de su aplicación (ejemplos: Vercel, Heroku).
 3. **SaaS (Software as a Service):** Es software listo para usar que resuelve problemas puntuales. El cliente solo interactúa con la interfaz para enviar peticiones y obtener resultados; el proveedor gestiona absolutamente todo, desde la infraestructura hasta las reglas de negocio del software (ejemplos: Gmail, Salesforce).
-

Ventajas Principales

- **Accesibilidad y Disponibilidad:** Permite el acceso a la información y herramientas desde cualquier lugar del mundo con conexión a internet, garantizando que los servicios estén siempre operativos (**Alta Disponibilidad**).
- **Eficiencia de Costos:** Se eliminan los gastos de inversión inicial en hardware físico y mantenimiento. Bajo el modelo de **pago por uso**, solo pagas por los recursos que realmente consumes, transformando costos fijos en variables.

Multiprocesadores

Multiprocesador: Máquina con más de una unidad de procesamiento.

Es una máquina de memoria compartida que permite que una computadora trabaje más rápido, ejecute varias tareas a la vez y resuelva problemas complejos de manera más eficiente.

Existen dos tipos de multiprocesadores:

- Microprocesador multicore: Un procesador con muchos núcleos.
- Microprocesadores múltiples: Varios microprocesadores conectados por un sistema de interconexión (buses).

La **coherencia de caché** evita que la CPU lea valores desactualizados de las ubicaciones en memoria. Cada CPU posee su propia memoria caché, pero comparten la memoria RAM, provocando en muchos casos que tengan copias de las mismas posiciones en memoria dentro de sus cachés.

Una **invalidación** surge cuándo un Thread modifica una línea de caché y esta misma se encuentra en otra caché de otro procesador, para evitar inconsistencias se invalida la línea.

Al invalidar la línea se genera otro problema denominado falsa compartición. La **falsa compartición** es un problema de rendimiento producido por las invalidaciones que hacen que los protocolos de coherencia de caché se realicen sobre la línea completa en caché en vez de la unidad mínima direccionable que es el byte. Este problema puede ocasionar problemas dentro del rendimiento. Para solucionarlo se suele separar a una distancia de una palabra los datos que son compartidos.

Clasificación

Las máquinas de memoria compartida se clasifican en **UMA** Y **NUMA** según el tiempo de acceso (latencia) a la RAM.

UMA: Uniform Acces Memory. El tiempo de acceso a cualquier ubicación de la memoria es el mismo para todos los procesadores.

NUMA: Non Uniform Acces Memory: El tiempo de acceso a la memoria no es el mismo para todos los procesadores.

Multicomputadores

Multicomputador

Es una máquina MIMD de memoria distribuida compuesta por múltiples computadores conectados por una fuerte red de comunicaciones.

Sus nodos son homogéneos, osea que tienen las mismas características, eso hace que sea más fácil repartir tareas y que el rendimiento sea más predecible.

Es más económico y mejor construir el multicomputador a partir de otros computadores más pequeños, que hacer una máquina solo indivisible. este es más escalable que un multiprocesador.

Tipos de multicomputador

CLUSTER: Es un multicomputador que está construido a partir de productos comerciales que están hechos para otros propósitos. Los nodos del clúster están interconectados a través de redes de área local.

MPP (Massively Parallel Processor): Es un supercomputador que su tecnología de hardware especializada y dedicada a supercomputadores, que es más cara de hacer que un cluster.

Tipos de nodos en un cluster

- Nodos de **CÓMPUTO**
- Nodos de **ALMACENAMIENTO**
- Nodo **CABEZA:** Se utiliza para lanzar trabajos a ejecutar en nodos de cómputo. No se deben ejecutar trabajos de cómputo intensivo.

Gestor de Colas: Para lanzar trabajos, los clústeres tienen típicamente instalados un gestor de colas que permiten planificar la ejecución de trabajos en el clúster.

* Cuando **se lanza un trabajo** se especifica: nombre de la aplicación y sus parámetros, y recursos requeridos por la aplicación

Grid computing

Grid Computing

Sistema distribuido que permite a los usuarios lanzar aplicaciones usando recursos informáticos según necesidad y con poco o ningún conocimiento de la ubicación de los recursos y las tecnologías subyacentes.

Normalmente se construyen a partir de componentes heterogéneos, débilmente acoplados y geográficamente dispersos.

- ★ No tienen administración central
- ★ Utilizan estándares abiertos
- ★ Calidad de servicio no trivial (se consideran aspectos como seguridad, etc.)

Relación con Sistemas Paralelos:

Ambos buscan resolver problemas usando varios recursos de cómputo al mismo tiempo. En el grid, muchas computadoras distribuidas trabajan juntas, lo que permite ejecutar tareas en paralelo y reducir el tiempo de procesamiento.

Relación con Ciencias de la Computación:

Permite disminuir el tiempo de ejecución y **proporciona la subdivisión de tareas**, lo que puede reducir la dificultad de algunos problemas computacionales, ya que varias computadoras pueden trabajar juntas en paralelo como si fuera una **supercomputadora**.

Relación con Sistemas de Información

Podría permitir usar **muchos recursos informáticos distribuidos para procesar grandes cantidades de datos**. Esto es útil para diseñar y gestionar sistemas que necesitan alta capacidad de procesamiento y almacenamiento.

Benchmarks

Benchmarks en Sistemas Paralelos

En **sistemas paralelos** los benchmarks se utilizan para evaluar cómo se comporta el sistema cuando varias unidades de procesamiento trabajan al mismo tiempo. Cada una de las **métricas** permite analizar un aspecto distinto del rendimiento del sistema:

1. Speedup (cuánto mejora el rendimiento con paralelismo)

Mide **cuánto más rápido se ejecuta un programa cuando se usa paralelismo** en comparación con la ejecución secuencial.

Se calcula como: $\text{Speedup} = T_{\text{secuencial}} / T_{\text{paralelo}}$
donde:

$T_{\text{secuencial}}$ = tiempo de ejecución en **un solo procesador**

T_{paralelo} = tiempo usando **varios procesadores**

Interpretación:

Speedup = 1 → no hay mejora.

Speedup = 2 → el programa corre el doble de rápido.

Speedup = N (con N procesadores) → speedup ideal o lineal.

En la práctica nunca se alcanza el speedup perfecto debido a comunicación entre procesos, sincronización, partes del programa que no se pueden paralelizar (Ley de Amdahl [describe el límite teórico de speedup que se puede obtener]).

Por eso los benchmarks permiten ver qué tan cerca está el sistema del rendimiento ideal.

2. Escalabilidad

Indica qué tan bien el sistema **mantiene su rendimiento al aumentar la cantidad de procesadores** o nodos. Hay dos tipos comunes:

Escalabilidad fuerte (Strong Scaling)

Se **mantiene el mismo problema, pero se agregan más procesadores**. Se observa si el tiempo de ejecución disminuye proporcionalmente.

Ejemplo:

Si el tiempo baja casi proporcionalmente, el sistema escala bien.

Procesadores	Tiempo
1	100 s
2	55 s
4	30 s

Escalabilidad débil (Weak Scaling)

Se **aumenta el tamaño del problema junto con la cantidad de procesadores**. La idea es ver si el tiempo de ejecución se mantiene aproximadamente constante.

Ejemplo:

Si el tiempo se mantiene estable, el sistema escala correctamente. Los benchmarks

ayudan a determinar hasta qué punto agregar más procesadores sigue siendo útil.

Procesadores	Tamaño problema	Tiempo
1	1000 datos	10 s
2	2000 datos	11 s
4	4000 datos	10 s

3. Uso eficiente de procesadores

Analiza **si todos los procesadores están siendo utilizados de manera efectiva**. Se mide con la eficiencia paralela: $E = \text{Speedup} / N$
donde: N = número de procesadores

Interpretación: $E \approx 1 \rightarrow$ uso muy eficiente
 E baja $\rightarrow$ procesadores ociosos o esperando

Problemas comunes detectados por benchmarks: demasiada comunicación entre procesos, secciones críticas que bloquean ejecución, procesos esperando sincronización, tareas mal distribuidas
Esto permite optimizar algoritmos paralelos.

4. Rendimiento de red entre nodos

En **sistemas paralelos distribuidos** (clusters), los nodos deben **intercambiar datos constantemente**.

Por eso los benchmarks también miden la **performance de la red**, principalmente:

Latencia: Tiempo que tarda un mensaje en viajar entre dos nodos.

Latencia baja $\rightarrow$ comunicación más rápida.

Ancho de banda: Cantidad de datos que pueden transmitirse por segundo.

Mayor ancho de banda $\rightarrow$ mejor transferencia de grandes volúmenes de datos.

Si la red es lenta, los procesadores pasan más tiempo esperando datos que computando.

5. Balance de carga

Mide **qué tan equilibradamente se distribuye el trabajo entre los procesadores**.

Idealmente: todos los procesadores deberían terminar su trabajo aproximadamente al **mismo tiempo**.

Problema típico: El sistema debe esperar a que termine el más lento (P1-P3).

Esto significa que:

- algunos procesadores **quedan ociosos**
- se pierde **eficiencia paralela**

Los benchmarks permiten detectar:

- **distribución desigual** de tareas
- **algoritmos de partición ineficientes**
- problemas de **sincronización**

Luego se aplican técnicas como:

- load balancing dinámico
- partición más uniforme de datos
- planificación de tareas (scheduling)

Procesador	Tiempo de trabajo
P1	10 s
P2	10 s
P3	10 s
P4	3 s

Métricas de rendimiento

Métricas de rendimiento: Eficiencia Computacional y Energética

Para medir la eficiencia energética de los sistemas HPC se utilizan principalmente dos métricas:

- **GFLOPS/WATT = GFLOP/Joule** (usado por el Green500): es decir, la cantidad de mil millones de operaciones de punto flotante por segundo (energía, capacidad de trabajo, medida sobre un período) por WATT (potencia, energía transferida por unidad de tiempo, medida en cualquier instante) consumido.
- **Total Watts/IT Watts** (Power Usage Effectiveness, usada en centros de computación): cantidad total de energía usada para refrigeración, iluminación, etc. respecto a la que alimenta exclusivamente el sistema de cómputo, de forma que el idea es 1 (toda la energía se usa en cómputo), y 2 se considera alto.

Estos valores están fuertemente relacionados a la velocidad de cómputo (eficiencia computacional), cuyas principales métricas son:

- MIPS (millones de instrucciones máquina por segundo), las instrucciones son invisibles al programador (dependen del hardware), no es útil para analizar la eficiencia.
- FLOPS (operaciones de punto flotante por segundo), las operaciones de punto flotante son generalmente usadas por científicos en los sistemas HPC, siendo la métrica más necesaria.

Evolución de la eficiencia energética

Meet: <https://meet.google.com/smk-ztyr-ioo>

La eficiencia energética de las computadoras se basa en el consumo de energía para procesar instrucciones. Según la clasificación semestral Green500, se expresa como:

$$\frac{MFLOPS}{Watts}$$

Durante la evolución de las computadoras se observó una tendencia en la que cada 18 meses, la eficiencia energética se duplicaba. A esta observación se la conoce como ley de Koomey.

Koomey en un artículo propone la idea de que para mejorar la eficiencia energética, se puede aprovechar las señales electromagnéticas que se encuentran en el aire para cosecharlas con un antena grande, y si contamos con un dispositivo ultra eficiente, esta podría funcionar con sólo recibir las pequeñas dosis de energía que la antena puede ofrecer.

Se habla también de que porque queríamos reducir el consumo energético, dando razones como la energía limitada de los dispositivos móviles, la barrera energética en procesadores y que las supercomputadoras consumen tanta energía que producen impactos económicos, sociales y medioambientales, y se buscaría reducir eso con la reducción del consumo energético.

Evolución del tamaño

Evolución de tamaño:

El avance histórico de la tecnología con la que se implementan las computadoras marca una evolución en potencia, pero también tamaño.

Las primeras máquinas de cómputo eran de tipo mecánicas, y permitían realizar simples cálculos matemáticos. Luego surgieron aquellas de tubos de vacío, permitiendo mayor cálculo. Sin embargo, estas primeras computadoras ocupaban espacios gigantescos si los comparamos con computadoras actuales, debido a las tecnologías utilizadas.

Con la llegada de los transistores como tecnología principal utilizada para construir procesadores, esta situación cambió rápidamente. La Ley de Moore plantea que cada 2 años, se duplica el número de transistores en los procesadores. Esto quiere decir, que si la tecnología utilizada por los transistores es la misma, y tenemos que duplicar la cantidad, entonces tendríamos que duplicar el tamaño de los chips. Sin embargo, esto no ocurre de esta manera, dado que los transistores son cada vez más pequeños (más miniaturizados), lo que permite empaquetarlos para crear circuitos integrados de menor tamaño, pero igual o mayor capacidad de computación.

Por último, se habla de cuántos años más va a seguir vigente esta ley porque se está llegando a un punto donde es cada vez más difícil integrar más transistores dentro del mismo espacio, esto es el problema llamado el muro de poder o power wall.